

Predicția Randamentului Producției de Mere

Pop Adrian Corneliu

May 2026

1 Introducere

Producția agricolă mondială este supusă unor variații semnificative determinate de factori climatici, caracteristicile solului și practicile agricole. Estimarea timpurie și precisă a randamentului culturilor reprezintă o prioritate strategică pentru planificarea eficientă a resurselor și adaptarea la schimbările climatice.

Acest proiect dezvoltă și antrenează un sistem de Machine Learning capabil să estimeze randamentul producției de mere (Yield, exprimat în hg/ha) la nivelul unui număr de țări, pe baza datelor istorice de producție și a factorilor climatici asociați.

Modelul este antrenat pe un dataset integrat care acoperă zeci de țări și regiuni din toate continentele, pe o perioadă de 15 ani (2005-2019)

Obiectiv principal: predicția randamentului producției de mere (hg/ha) per țară și an, utilizând date climatice care afectează randamentul, cu scopul de a prezice randamentul pe ani viitori.

1.1 Contextul Problemei

Mărul (*Malus domestica*) este una dintre cele mai cultivate specii de pomi fructiferi la nivel mondial, cu o producție anuală de peste 80 de milioane de tone. Randamentul său este influențat de o multitudine de factori:

- Temperatura medie anuală și temperaturile înregistrate în fiecare sezon
- Precipitațiile totale înregistrate în sezoanele de creștere și dezvoltare a pomului
- Numărul de zile de îngheț, în special primăvara, în perioada de înflorire
- Umiditatea solului în sezonul de creștere
- Suprafața cultivată și intensitatea producției

Complexitatea acestor interacțiuni face ca modelele de regresie liniară clasice să fie insuficiente, justificând utilizarea algoritmilor de tip ansamblu bazați pe arbori de decizie.

2 Arhitectura și Sursele de Date

Datasetul final utilizat în antrenament a fost realizat în urma combinării a trei surse de date, îmbinate după cheia comună (Țară, An). Procesul de preluare a datelor și îmbinare a acestora este detaliat în notebook-ul principal (`main.ipynb`) și în scriptul de extracție climatică (`clima.ipynb`).

2.1 Date de Producție — FAO / Kaggle

- **Sursă** — Kaggle `crop-statistics-fao-all-countries` (sursa inițială fiind FAO).

Datele de producție preluate din acest dataset au o acoperire globală pentru perioada 1961–2023 și un număr mare de țări, zone și specii de pomi fructiferi.

În cadrul acestui proiect, datele au fost filtrate pentru a prelua doar datele pentru specia de "Meri" fiind extrase și transformate trei variabile principale:

- **Area harvested** — suprafața recoltată, exprimată în hectare (ha).
- **Production** — producția totală, exprimată în tone (t).
- **Yield** — randamentul producției, exprimat în hectograme per hectar (hg/ha), reprezentând *variabila țintă* a modelului.

Pe acest dataset s-a aplicat o transformare suplimentară pentru a trece de la formatul de "un rând per element (Area harvested, Production, Yield)" la formatul desfășurat, respectiv "un rând per țară și an".

Datasetul rezultat constă în valori pe totii ani prezenți inițial în datasete. Însă pe aceste date trebuie aplicate diferite verificări deoarece din diferite motive precum lipsa măsurătorilor (exemplu anii 1900 - 2000), anumite date pot să lipsească. Astfel se fac verificări de valori nule sau duplicate și se elimină anii/rândurile pe care nu se poate aplica interpolare. Se calculează care sunt anii care înregistrează valori lipsă și se elimină acei ani din tot datasetul pentru a avea același număr și aceiași ani pentru toate țările. După toate aceste modificări, rezultatul este salvat într-un nou fișier (.csv) numit "Dataset_Mere_Final.csv".

2.2 Date Climatice — NASA POWER API

- **Sursă**: NASA POWER — <https://power.larc.nasa.gov/api/temporal/daily/point>

Punctele geografice pentru extragerea au fost definite în fișierul `config` sub forma "Țară": **coordonate (lat/long)**. Pe baza acestor puncte au fost extrase date climatice zilnice care au fost agregate lunar, anual și pe sezoane. S-a asigurat acoperirea tuturor țărilor, zonelor și anilor din fișierul final de producție.

Datele climatice au fost extrase prin apeluri API individuale pentru coordonatele fiecărei țări. Variabilele sunt organizate pe sezoane (Primăvară, Vară), relevante pentru creșterea și dezvoltarea mărului:

Variabilă	Sezon	Relevanță Agronomică
Temp_Medie_An	Anual	Condițiile termice generale
Precip_Tot_An	Anual	Disponibilul total de apă
Zile_Inghet_An	Anual	Riscul global de îngheț
Temp_Max_primavara	Primăvară	Stres termic la înflorire
Precip_primavara	Primăvară	Apă disponibilă la înflorire
Inghet_primavara	Primăvară	Distrușgerea florilor
Umid_Sol_primavara	Primăvară	Umiditate sol la înflorire
Temp_Max_vara	Vară	Stres termic la creșterea fructelor
Precip_vara	Vară	Irigare naturală a fructelor
Inghet_vara	Vară	Deteriorare fructe (rar)
Umid_Sol_vara	Vară	Disponibil hidric la maturare

3 Preprocesarea și Curățarea Datelor

Procesul de curățare a datelor cuprinde mai multe etape, implementate în notebook-urile `main.ipynb` și `clima.ipynb`, asigurând calitatea și consistența datelor înainte de antrenament.

3.1 Filtrarea și Selecția Inițială

- Filtrarea exclusivă pe specia *Apples* din datasetul FAO (eliminarea celorlalte peste 170 de culturi).
- Eliminarea anilor anteriori lui 2005 — perioadă cu date climatice incomplete sau lipsă din API.
- Eliminarea coloanelor redundante: *Area Code*, *Item Code*, *Element Code*, *Year Code*, *Flag*.
- Transformarea randurilor centralizate pe elemente (Area Harvested, Yeld, Production) în rânduri centralizate pe țară și an

3.2 Tratatamentul Valorilor Lipsă

Verificarea valorilor nule a fost efectuată pe fiecare coloană înainte și după procesul de integrare a datelor climatice. Strategia aplicată:

- Interpolarea liniară pentru anii care aveau ani lipsă, unde era posibil
- Eliminarea rândurilor cu valori null pe coloanele esențiale (*Area harvested*, *Yield*) — rânduri care nu pot fi interpolate.
- Verificare finală: zero valori null în datasetul de antrenament.

3.3 Tratatamentul Valorilor Zero

A fost calculat procentul de valori zero per coloană. Coloanele cu procent ridicat de zerouri (ex: *Inghet_vara_crestere* — zile de îngheț vara) au fost reținute în model deoarece reflectă o realitate agronomică (înghețul vara este rar), nu o eroare de date.

4 Analiza Datelor

4.1 Matrice de corelație




Figura 1: Matricea de corelație

Matricea de corelație prezintă relațiile liniare dintre 15 variabile numerice ce descriu producția de mere și condițiile climatice asociate. Valorile coeficientului de corelație Pearson variază între -1 și 1 , unde valorile apropiate de ± 1 indică o relație puternică, iar cele apropiate de 0 indică absența unei relații liniare.

Corelații foarte puternice ($|r| > 0.85$)

Pozitive:

- **Area harvested** $\leftrightarrow$ **Production** ($r = 0.98$) — suprafața recoltată explică variația producției și a randamentului; cu cât suprafața e mai mare, cu atât șansa ca producția și randamentul să crească
- **Zile_Inghet_An** $\leftrightarrow$ **Inghet_primavara_critica** ($r = 0.95$) — zilele de îngheț anual sunt dominate de îngheturile de primăvară
- **Precip_primavara_critica** $\leftrightarrow$ **Precip_Tot_An** ($r = 0.82$) — precipitațiile de primăvară contribuie major la totalul anual

Negative:

- **Temp_Medie_An** $\leftrightarrow$ **Zile_Inghet_An** ($r = -0.89$) — cu cât temperatura medie anuală este mai ridicată, cu atât zilele de îngheț scad

- **Temp_Medie_An** $\leftrightarrow$ **Inghet_primavara_critica** ($r = -0.85$) — temperaturile mai ridicate reduc riscul de îngheț critic de primăvară
- **Temp_Max_primavara_critica** $\leftrightarrow$ **Zile_Inghet_An** ($r = -0.62$) — corelație moderată inversă

Cea mai puternică corelație din matrice se înregistrează între **Area harvested** și **Production** ($r = 0.98$), ceea ce este de așteptat — suprafața cultivată determină în mod direct volumul producției. Această relație aproape perfectă sugerează că, în setul de date analizat, randamentul pe unitatea de suprafață (*Yield*) a rămas relativ constant de-a lungul timpului, producția totală variind în principal în funcție de suprafața recoltată.

În ceea ce privește variabilele climatice, se remarcă un **cluster termic** bine definit. Temperatura medie anuală (*Temp_Medie_An*) corelează puternic negativ cu numărul zilelor de îngheț anual ($r = -0.89$) și cu înghețurile critice de primăvară ($r = -0.85$), ceea ce reflectă o logică meteorologică firească — anii mai calzi înseamnă mai puține zile de îngheț. Complementar, zilele de îngheț anual și înghețurile de primăvară critice sunt puternic corelate pozitiv între ele ($r = 0.95$), indicând că înghețurile de primăvară contribuie cel mai mult la numărul înghețurilor anuale totale.

Un al doilea grup coerent de variabile este cel **hidric**. Precipitațiile totale anuale corelează moderat cu precipitațiile din primăvara critică ($r = 0.82$) și cu umiditatea solului în sezonul de vară ($r = 0.71$), sugerând că precipitațiile de primăvară influențează semnificativ rezerva de apă din sol pe parcursul întregului sezon de vegetație.

Un aspect notabil îl reprezintă **slaba corelație dintre variabilele de producție și factorii climatici**. *Yield*, *Area harvested* și *Production* nu prezintă corelații semnificative cu niciuna dintre variabilele climatice incluse (majoritatea $|r| < 0.15$). Aceasta sugerează că influența climei asupra producției de mere nu este reprezentată printr-o relație liniară simplă, fiind probabil afectată de media mai multor factori sau de prezența unor relații neliniare.

Variabila **Year** nu corelează semnificativ cu nicio altă variabilă din setul de date, ceea ce indică absența unor tendințe temporale clare — fie că variabilele nu s-au schimbat în timp, sau este o variație anuală mare.

Deși variabila țintă **Yield** nu prezintă corelații liniare semnificative cu factorii climatici incluși în analiză, aceasta nu exclude existența unor relații neliniare sau interactive între variabile. Matricea de corelație evidențiază totuși structura internă a factorilor climatici, relevantă pentru înțelegerea coliniarității multiple și pentru selecția featurilor în modelele precum RandomForest, Extra Trees și XGBoost.

4.2 Scatter plot suprafață vs randament




Figura 2: Relația Randament vs An




Figura 3: Relația Randament vs Zile îngheț an

Yield vs Year — punctele sunt foarte dispersate vertical pentru fiecare an, iar linia de trend este aproape orizontală cu o ușoară pantă pozitivă. Asta confirmă că nu există o tendință temporală clară în randament de-a lungul celor ~ 15 ani, explicând astfel corelația slabă ($r = 0.08$) din matrice. Variabilitatea mare între țări în același an explică norul dens de puncte pe fiecare coloană verticală.

Yield vs Zile Îngheț An — linia de trend are o pantă ușor negativă, confirmând corelația ($r = -0.11$) din matrice — mai multe zile de îngheț tind să fie asociate cu randamente ușor mai mici. Însă dispersia este enormă, mai ales în zona 0–150 zile, ceea ce explică de ce corelația liniară rămâne slabă. De remarcat că valorile extreme de Yield (peste 500.000) apar preponderent în zona cu puține zile de îngheț, sugerând o relație neliniară — praguri de îngheț peste care randamentul scade semnificativ, tocmai tipul de relație pe care Random Forest, XGBoost și Extra Trees o captează bine.




Figura 4: Relația Log(Randament) vs Zile îngheț an

Log(Yield) vs Zile Îngheț An — aplicarea transformării logaritmice asupra randamentului comprimă valorile extreme și reduce asimetria distribuției, făcând relația mai vizibilă. Linia de trend negativă devine mai stabilă și intervalul de încredere se îngustează față de scala originală, confirmând tendința de scădere a randamentului odată cu creșterea numărului de zile de îngheț. În detrimentul avantajelor pe care le aduce, aplicarea logaritmului deși oferă o stabilitate mai ridicată a rezultatelor pentru modele precum **Random Forest**, **Extra Trees** și **XGBoost** nu crește acuratețea, ci dinpotrivă acuratețea scade.

Posibilele cauze ale lipsei de îmbunătățire în acest caz pot fi faptul că logaritizarea funcționează mai bine pe modelele liniare și datasetul nostru nu prezintă relații liniare bine dezvoltate. Totodată datasetul folosit este un dataset relativ mic (1747 rânduri) și modelul nu are destule date ca să explore avantajele logaritmului. De asemenea, în cazul nostru un model învață mai mult din relația dintre Țară și Yield ("ce țară este") decât din forma distribuției Yield-ului.

4.3 Distribuția variabilei țintă




Figura 5: Distribuția Randamentului (Yield)

Distribuția randamentului prezintă o asimetrie pozitivă. Majoritatea valorilor sunt situate în intervalul 0–200.000, cu o coadă lungă spre dreapta ce se extinde până la 800.000. Această formă este tipică pentru date agricole, unde majoritatea țărilor înregistrează randamente moderate, iar valorile foarte ridicate reprezintă excepții datorate condițiilor optime sau tehnologiei avansate. Asimetria distribuției a motivat adăugarea logaritmului, însă modelele de tip ansamblu utilizate (Extra Trees, Random Forest, XGBoost) s-au dovedit robuste, obținând rezultate bune și pe scala originală.

5 Metodologia de Machine Learning

5.1 Definirea Problemei

Problema este formulată ca o regresie supervizată: pe baza unui set de variabile de intrare (climatice, de producție), se prezice variabila țintă *Yield* (hg/ha).

Datasetul pe care sunt antrenate modelele are 1747 rânduri și conține date despre producția merilor și date climatice pe o perioadă de 15 ani (2005 - 2019), structurate pe ani și țări.

5.2 Strategia de Split Temporal

Pentru a simula corect un scenariu de predicție reală pe ani viitori, s-a utilizat o metodă de împărțire bazată exclusiv pe timp. Aceasta previne fenomenul de *data leakage*.

Split temporal: primii 70% ani pentru antrenament — ultimii 30% ani pentru test. Nu s-a utilizat random split, pentru a respecta ordinea temporală a datelor.

Împărțirea temporală reflectă realitatea operațională: modelul este antrenat pe date istorice și trebuie să facă predicții pentru ani viitori nevăzuți. Un *random split* ar fi amestecat datele din anii precedenți cu date din ani viitori.

5.3 Validare Încrucișată — TimeSeriesSplit

Pentru estimarea stabilității modelului și prevenirea overfitting-ului în procesul de selecție a hiperparametrilor, s-a aplicat `TimeSeriesSplit` cu 5 fold-uri. Această metodă de cross-validation respectă ordinea temporală: fiecare fold/ nivel de validare este cronologic după fold-ului de antrenament corespunzător.

5.4 Spațiul de Căutare a Hiperparametrilor

Optimizarea hiperparametrilor s-a realizat prin `RandomizedSearchCV` cu `n_iter=100`. Această metodă a fost preferată față de `GridSearchCV` deoarece, în loc să testeze toate combinațiile posibile de parametri, selectează aleatoriu 100 de combinații din spațiul de căutare definit. Astfel, timpul de antrenare este redus semnificativ, păstrând în același timp o explorare suficient de largă a parametrilor pentru a găsi o configurație bună.

Model	Hiperparametri Căutați	Distribuție
Ridge / Lasso	alpha	Uniform(0.01, 20)
Decision Tree	max_depth, min_samples_split, criterion	Liste / Randint
Random Forest	n_estimators, max_depth, max_features, bootstrap	Randint(100..800)
Extra Trees	n_estimators, max_depth, min_samples_leaf, max_features	Randint(480..580)
XGBoost	learning_rate, n_estimators, max_depth, subsample, gamma	Uniform / Randint
AdaBoost	n_estimators, learning_rate, loss	Randint / Uniform

Tabela 1: Spațiul de căutare a hiperparametrilor pentru fiecare model

6 Modele Evaluate și Rezultate

Au fost evaluați 8 algoritmi de regresie, de la modele liniare clasice până la modele de tip ansamblu bazate pe arbori de decizie. Pentru evaluare s-au folosit patru metrici: R^2 Train, R^2 Test ca metrică principală, Variație calculată ca diferența dintre R^2 Train și R^2 Test, Bias și MAE pe setul de test.

6.1 Rezultate — Target: Yield (hg/ha)

Model	R^2 Train	R^2 Test	Varianță	Bias	MAE Test (hg/ha)
Linear Regression	0.2600	0.2235	0.0365	0.74	85,316
Ridge	0.2551	0.2228	0.0322	0.74	85,623
Lasso	0.2600	0.2235	0.0365	0.74	85,317
Decision Tree	0.1874	0.1618	0.0256	0.81	87,653
AdaBoost	0.2558	0.2410	0.0148	0.74	94,664
Random Forest	0.8367	0.6752	0.1615	0.16	53,964
XGBoost	0.8798	0.6947	0.1851	0.12	51,965
Extra Trees	0.8905	0.7928	0.0977	0.11	43,178

Tabela 2: Rezultatele modelelor evaluate

6.2 Analiza Rezultate

6.2.1 Modele Liniare (Ridge, Lasso, Linear Regression)

Toate trei obțin un R^2 Test în jurul valorii de 0.22, ceea ce înseamnă că explică doar 22% din variația randamentului. Biasul foarte mic (sub 0.04) arată că modelele nu sunt în overfitting — problema este că relația dintre variabilele climatice și randament nu este liniară, iar aceste modele nu au capacitatea să o surprindă.

6.2.2 Decision Tree și AdaBoost

Performanță modestă, cu R^2 Test între 0.16 și 0.31. Un singur arbore de decizie nu reușește să capteze interacțiunile complexe dintre variabilele climatice, iar AdaBoost este limitat de faptul că combină modele de bază simple care individual nu performează bine pe acest tip de date.

6.2.3 Random Forest și XGBoost

Față de modelele anterioare, se observă un salt important de performanță — R^2 Test între 0.69 și 0.73. Ambele modele reușesc să capteze relațiile neliniare din date, însă biasul de aproximativ 0.18 indică un grad moderat de overfitting, adică modelele au învățat parțial zgomotul din setul de antrenare.

6.2.4 Extra Trees — Modelul Câștigător

Extra Trees obține cel mai bun rezultat: R^2 Test = 0.8534, MAE = 34,213 hg/ha și un bias de 0.103, cel mai mic dintre modelele de tip ansamblu. Față de Random Forest, Extra Trees introduce o randomizare suplimentară — pragurile de split sunt alese complet aleatoriu în loc să fie optimizate, ceea ce reduce tendința de overfitting și îmbunătățește generalizarea pe date nevăzute. Hiperparametrii optimi găsiți prin RandomizedSearchCV au fost: `n_estimators=515`, `max_depth=15`, `min_samples_leaf=5`, `max_features=log2`, `bootstrap=False`.

Model ales: Extra Trees Regressor — R^2 Test = 0.8534. Modelul explică 85.3% din variabilitatea randamentului pe date nevăzute, cu o eroare absolută medie de ~34,213 hg/ha (~3.4 tone/ha).

6.3 Combinarea Modelelor — Averaging și Voting

Pe lângă evaluarea individuală a modelelor, s-a testat dacă combinarea celor mai bune trei modele (Extra Trees, Random Forest, XGBoost) poate îmbunătăți performanța față de cel mai bun model individual.

S-au folosit două abordări. Prima este **Averaging** — predicțiile finale sunt media aritmetică a predicțiilor celor trei modele, fiecare contribuind în mod egal la rezultatul final. A doua este **Voting Ponderat** — similar cu Averaging, dar fiecare model contribuie proporțional cu R^2 -ul său pe setul de test, astfel încât modelele mai performante au o influență mai mare asupra predicției finale.

7 Importanța Variabilelor (Feature Importance)

Importanța variabilelor a fost extrasă din modelul Extra Trees folosind mecanismul nativ `feature_importances_`, bazat pe reducerea medie a impurității la fiecare split. Coloanele generate de encoding-ul binar al țării (`Area_0`, `Area_1` etc.) au fost grupate într-o singură valoare agregată `Area` (țară) pentru o interpretare mai clară.




Figura 6: Feature Importance — Extra Trees

Rang	Variabilă	Importanță	Interpretare Agronomică
1	Area (țară)	0.43	Țara de origine — reflectă diferențele structurale dintre țări
2	Temp_Medie_An	0.09	Temperatura medie anuală — condițiile termice generale
3	Zile_Inghet_An	0.07	Numărul total de zile de îngheț pe an
4	Temp_Max_vara_crestere	0.07	Temperatura maximă vară — stres termic la maturarea fructelor
5	Umid_Sol_primavara_critica	0.06	Umiditate sol primăvara — disponibil hidric la înflorire
6	Inghet_primavara_critica	0.05	Zile de îngheț primăvara — risc de afectare a florilor
7	Umid_Sol_vara_crestere	0.05	Umiditatea solului vară — irigare naturală a fructelor
8	Precip_vara_crestere	0.05	Precipitații vară — disponibil hidric în sezonul de creștere
9	Precip_Tot_An	0.04	Precipitații totale anuale — disponibilul hidric global
10	Inghet_vara_crestere	0.04	Îngheț vară — eveniment rar dar cu impact sever
11	Temp_Max_primavara_critica	0.04	Temperatura maximă primăvara — condiții la înflorire
12	Precip_primavara_critica	0.03	Precipitații primăvara — apă la înflorire și legarea fructelor

Tabela 3: Importanța variabilelor în modelul Extra Trees

Cel mai important predictor este **Area (țară)** cu o importanță de 0.43, ceea ce înseamnă că aproape jumătate din puterea predictivă a modelului vine din identificarea țării. Acest lucru reflectă diferențele structurale dintre țări — soiuri cultivate, tehnologie agricolă, condiții de sol — factori care nu sunt capturați direct de variabilele climatice incluse în dataset.

Dintre variabilele climatice, **Temp_Medie_An** este cel mai important predictor (0.09), urmată de **Zile_Inghet_An** (0.07) și **Temp_Max_vara_crestere** (0.07). Importanța ridicată a zilelor de îngheț confirmă teoria agronomică — temperaturile sub 0°C în perioada de înflorire distrug mugurii floriali și reduc drastic producția finală. Umiditate sol și precipitații au o importanță mai distribuită și mai mică, sugerând că temperatura este factorul climatic dominant pentru randamentul merelor.

8 Predicție Randament pe Țări Europene

Ca aplicație practică a modelului antrenat, s-a realizat o predicție a randamentului pentru toate țările europene din dataset, folosind mediile istorice ale variabilelor climatice pentru fiecare țară ca date de intrare. Astfel, predicția reprezintă randamentul estimat în condiții climatice tipice pentru fiecare țară.




Figura 7: Top 10 Țări Europa — Randament Estimat Mere (tone/ha)

Elveția ocupă primul loc cu un randament estimat de 50.05 tone/ha, valoare confirmată și de media reală din dataset de 58 tone/ha, reflectând agricultura elvețiană foarte intensivă și tehnologia avansată folosită în pomicultură. Urmează țările din Europa de Vest — Olanda, Franța, Italia, Slovenia și Belgia — cu randamente estimate între 32 și 35 tone/ha, consistent cu nivelul ridicat de mecanizare și intensificare agricolă din aceste țări.

România se situează pe locul 25 cu 11.47 tone/ha, iar Polonia pe locul 20 cu 14.19 tone/ha.

Un aspect important de menționat este că modelul tinde să **subestimeze randamentele foarte mari** — pentru Olanda, Franța și Italia diferența față de media reală este de 4–6 tone/ha. Acest comportament este tipic modelelor de tip ansamblu, care trag predicțiile spre media distribuției. În schimb, pentru țări cu randamente medii precum Polonia și România, predicțiile sunt mai precise, cu o diferență de sub 2 tone/ha față de valorile reale.

9 Posibile Îmbunătățiri

Deși modelul obține rezultate bune ($R^2 = 0.7928$), există mai multe direcții prin care performanța ar putea fi îmbunătățită.

Îmbogățirea datelor reprezintă probabil cel mai mare potențial de îmbunătățire. Adăugarea unor variabile agronomice precum soiul cultivat, tipul de sol, suprafața irigată sau consumul de fertilizanți ar putea reduce importanța dominantă a variabilei țară și ar oferi modelului informații mai direct legate de randament.

Creșterea volumului de date este de asemenea relevantă — datasetul actual de aproximativ 1.700 de înregistrări este relativ mic pentru modele de tip ansamblu. Extinderea perioadei de timp analizate sau includerea mai multor țări ar putea îmbunătăți generalizarea modelului.

Optimizarea hiperparametrilor poate fi continuată prin utilizarea **Optuna** — o bibliotecă de optimizare care explorează spațiul de hiperparametri mai inteligent decât **RandomizedSearchCV**, convergând mai rapid spre configurații optime.

Modele mai avansate precum **LightGBM** sau **CatBoost** ar putea fi testate, acestea fiind variante optimizate de gradient boosting care gestionează eficient variabilele categoriale (țara) și pot oferi performanțe superioare XGBoost pe dataseturi de dimensiuni medii.

10 Aplicații Posibile

Modelul Extra Trees antrenat poate fi utilizat în mai multe contexte practice din domeniul agricol.

Cea mai directă aplicație este **planificarea sezonului agricol** — fermierii și cooperativele agricole pot folosi prognozele meteorologice pentru sezonul următor ca input în model și pot obține o estimare a randamentului așteptat înainte de începerea sezonului. Aceasta permite decizii mai bune privind suprafața cultivată, necesarul de forță de muncă și negocierea contractelor de vânzare.

O altă aplicație este **evaluarea riscului climatic** — dat fiind că modelul a identificat temperatura medie anuală și zilele de îngheț ca factori dominanți, acesta poate fi folosit pentru a evalua impactul unor scenarii climatice extreme (primăveri foarte reci, veri caniculare) asupra randamentului estimat, util în special pentru companiile de asigurări agricole.

Modelul poate fi integrat și în **sisteme de suport pentru decizie** la nivel regional sau național, ajutând autoritățile să anticipeze producția totală de mere dintr-o regiune și să planifice importurile sau exporturile în consecință.

11 Concluzii

Scopul acestei lucrări a fost să determine dacă randamentul culturii de măr poate fi prezis cu ajutorul datelor climatice, folosind tehnici de machine learning. Au fost testați 8 algoritmi diferiți, de la regresie liniară simplă până la modele complexe bazate pe arbori de decizie.

Un prim rezultat important este că metodele clasice de regresie liniară nu funcționează bine pentru această problemă. Analiza corelațiilor a arătat că niciun factor climatic nu are o legătură liniară clară cu randamentul, iar modelele liniare au confirmat acest lucru obținând un R^2 de doar 0.22 — adică explică doar 22% din variația randamentului.

Modelele bazate pe arbori de decizie au dat rezultate mult mai bune, deoarece pot învăța relații complexe și neevidente din date. Cel mai bun model a fost **Extra Trees**, care a obținut un $R^2 = 0.7928$ pe datele de test, explicând astfel aproximativ 79% din variația randamentului pe date pe care nu le-a văzut în timpul antrenării.

Un aspect interesant descoperit prin analiza importanței variabilelor este că **țara** a fost cel mai important factor predictiv, cu o importanță de 0.43. Acest lucru are sens — fiecare țară are soiuri diferite de meri, tehnologii agricole diferite și condiții de sol diferite, factori care influențează randamentul dar nu sunt incluși direct în dataset. Dintre factorii climatici, **temperatura medie anuală** și **zilele de îngheț** au fost cei mai relevanți pentru predicție.

În concluzie, rezultatele arată că este posibil să prezici randamentul culturii de măr cu o acuratețe rezonabilă folosind doar date climatice și informații despre țară. Adăugarea unor date agronomice suplimentare — precum soiul cultivat sau tipul de sol — ar putea îmbunătăți semnificativ rezultatele în viitor.